UANL
UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FCFM
FACULTAD DE CIENCIAS FÍSICO MATEMÁTICAS

Reporte

DATOS MASIVOS

Para este tetramestre se usará un conjunto de datos extraido de Kaggle el cual contiene información de videos subidos a la plataforma de Youtube. Este conjunto de datos fue recopilado utilizando la API de YouTube.

Según la revista Variety, “para determinar los videos más populares del año, YouTube utiliza una combinación de factores que incluyen la medición de las interacciones de los usuarios (número de visualizaciones, compartidos, comentarios y ‘me gusta’).

Cabe destacar que no son necesariamente los videos más vistos en general durante el año calendario”.

Los videos con mejor desempeño en la lista de tendencias de YouTube suelen ser videos musicales, presentaciones de celebridades y/o programas de reality TV, y los clásicos videos virales de “una persona con una cámara” por los que YouTube es bien conocido.

Este conjunto de datos es un registro diario de los videos más populares en tendencia en YouTube.

Este conjunto de datos incluye varios meses (y sigue creciendo) de información sobre los videos diarios en tendencia en YouTube.

Los datos incluyen las regiones:

1. Estados Unidos (US)
2. Gran Bretaña (GB)
3. Alemania (DE)
4. Canadá (CA)
5. Francia (FR)
6. Rusia (RU)
7. México (MX)
8. Corea del Sur (KR)
9. Japón (JP)
10. India (IN)

Cada región tiene sus datos en archivos separados. La información incluye:

- Título del video
- Nombre del canal
- Fecha y hora de publicación
- Etiquetas (tags)
- Número de visualizaciones
- “Me gusta” y “No me gusta”
- Descripción
- Número de comentarios

El presente reporte tiene como objetivo hacer una exploración a los datos , revisar estadísticas básicas y principalmente realizar el análisis con MLlib de pyspark al conjunto de datos antes mencionado

Preparación de los datos

Dado que la información venía en archivos separados (JSON y CSV) para cada país (country) se procedio en primera instancia a crear una carpeta con la información de forma consolidada en un solo dataframe usando funciones de pyspark y sql y se crearon columnas con las etiquetas que corresponden.

Estadística descriptiva

Para este reporte en específico no se profundiza sobre la estadística descriptiva de los datos sin embargo se revisaron algunos boxplots para revisar de manera rápida algunas distribuciones de los datos que se tienen y algunas variables con las que se trabajaran

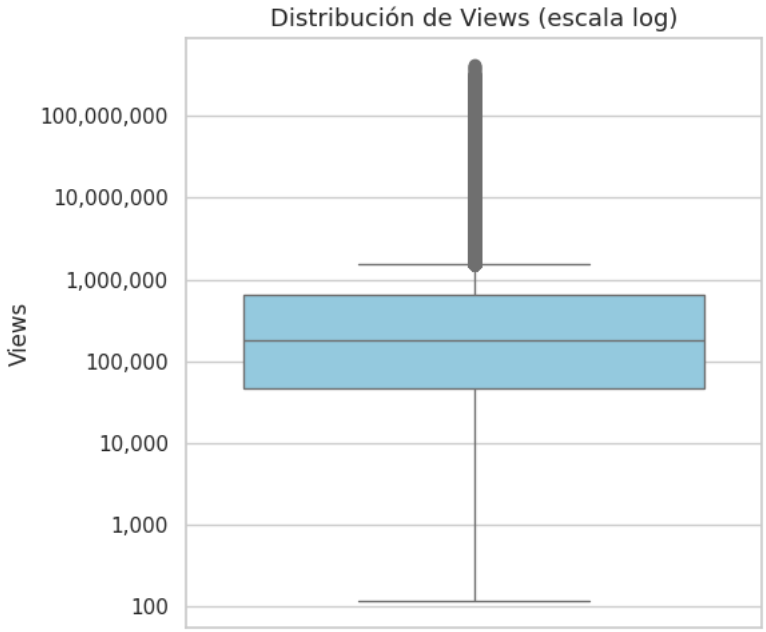

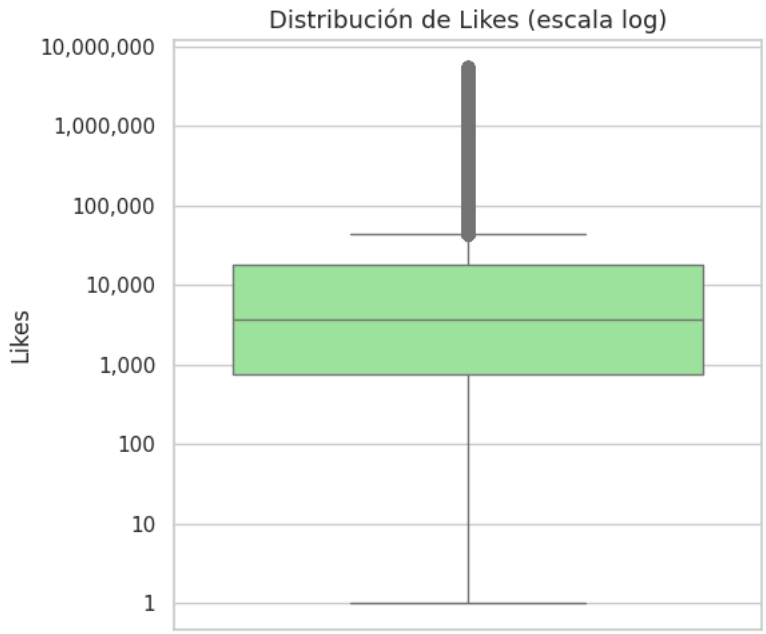

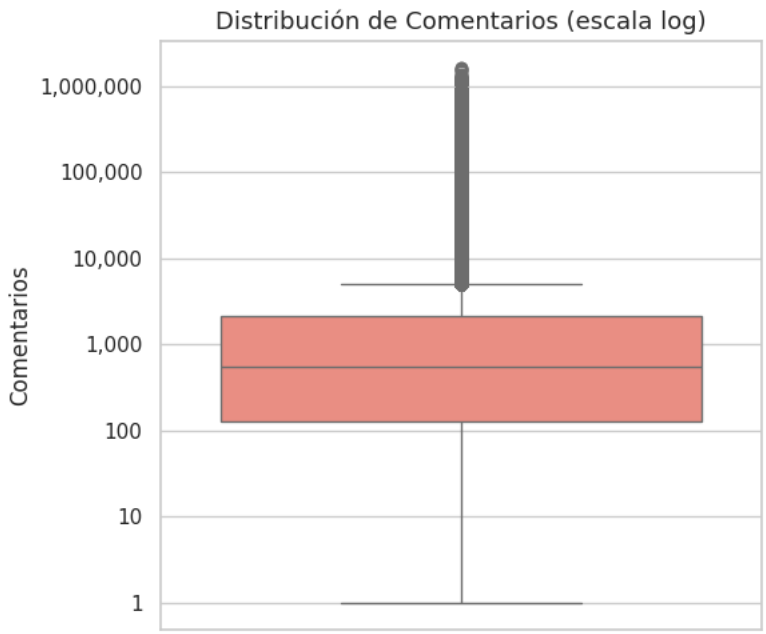

Asi mismo, antes de empezar a revisar algún modelo se corrió la matriz de correlación de las variables implicadas en este reporte con la finalidad de ver si hay algún tipo de linealidad entre ellas, las variables son las sigueintes:

- Views – Vistas totales del video
- Likes – Número total de ‘me gusta’ en el video
- Dislikes – Número total de ‘no me gusta’ en el video
- Comment_count –Número total de comentarios

-

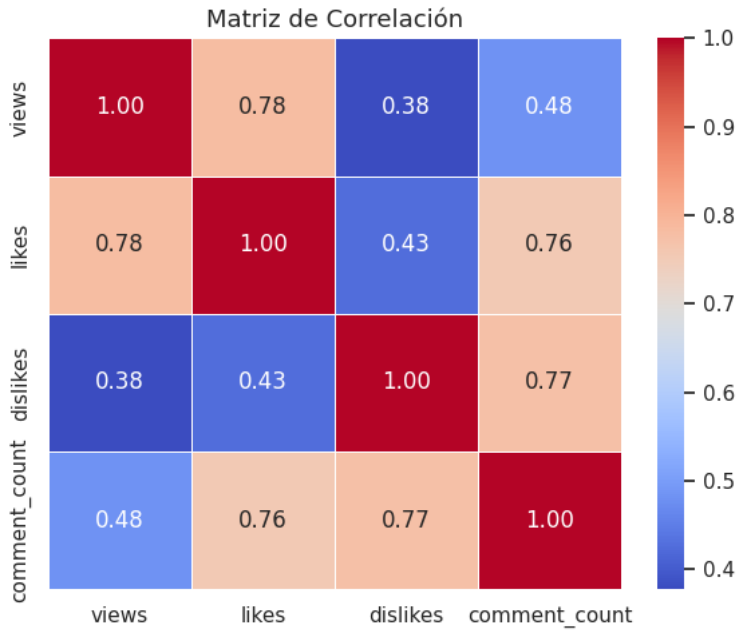

Engagement

Se creo una métrica con la finalidad de tener algo que medir con los datos llamada *'engagement'*, esta métrica sirve para medir qué tan activa es la audiencia respecto a las vistas en los videos, la fórmula usada es la siguiente:

$$engagement = \frac{likes + dislikes + comment_count}{views}$$

Para continuar con la exploración de datos se obtuvo una gráfica para ver qué países tienen más 'engagement', esta información puede ser útil para hacer análisis de los datos específicos en los países que tienen más o menos 'engagement' de la gráfica y hacer hipótesis dadas las comparaciones que puedan surgir con base en la siguiente imagen.

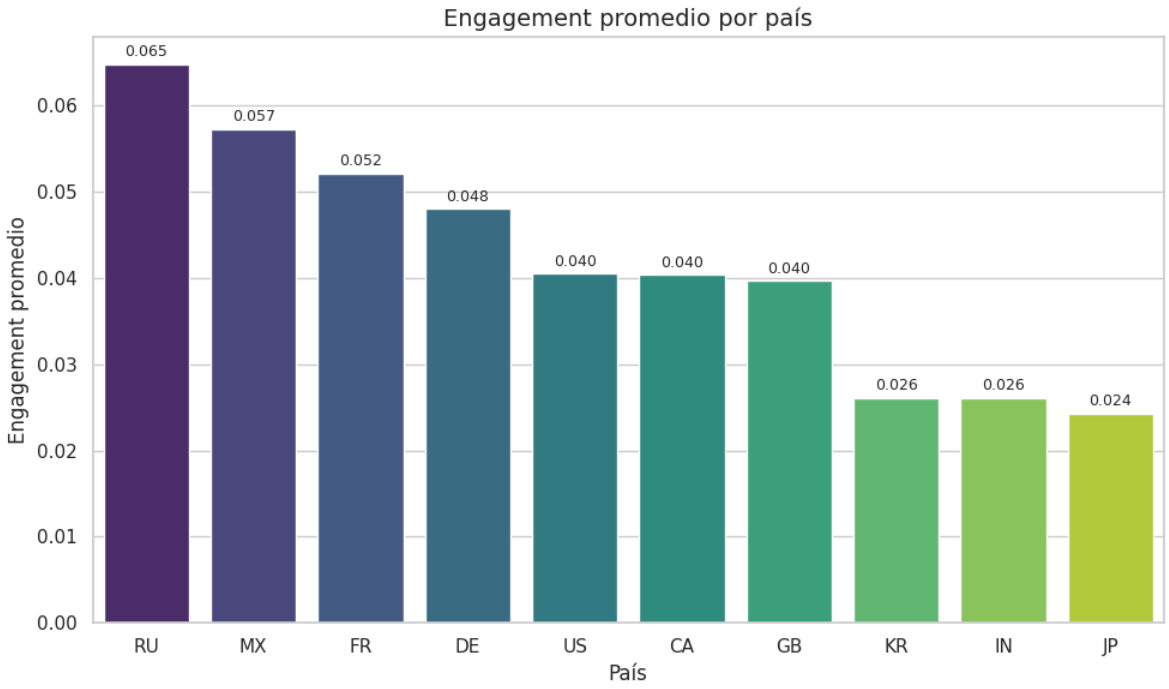

K-Means con MLlib

Procederemos a clasificar los videos dado el engagement. Las categorías que se usarán son:

- Alto engagement
- Bajo engagement
- Engagement medio

Para poder hacerlo, se realizó la 'prueba del codo' la cual se observa en la imagen siguiente.

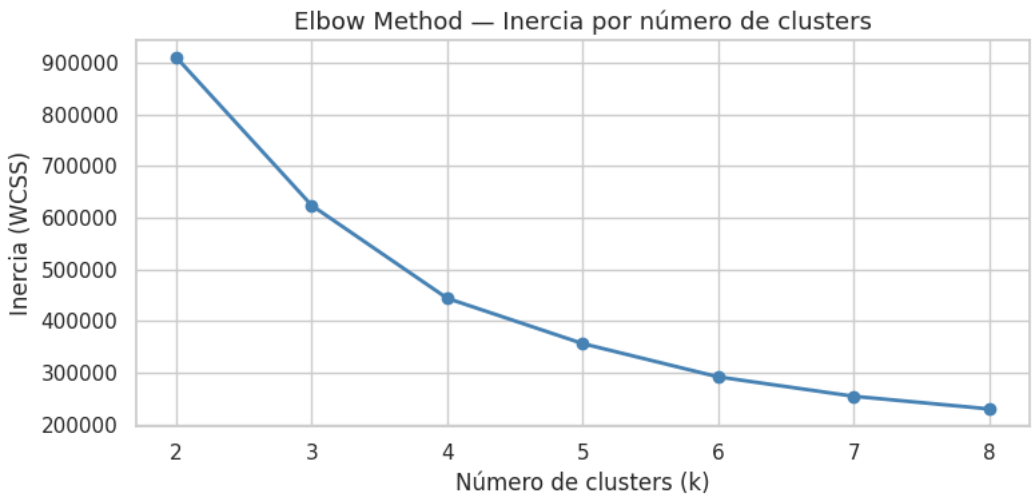

Si bien, pareciera que el númer0 intuitivo a elegir debe ser 4 o 5 se optó por usar 3 clusters (K=3) para una mejor clasificación (Alta, baja o media)

Resultados

Se decidió divir los clusters de la siguiente forma:

1. Engagement bajo (Cluster 0) – Engagement de 4.3%
   Aquí encontramos la gran mayoría del dataset con un total de 373,820 videos con un promedio de 971,205 vistas lo que nos indica que una gran cantidad de vistas (aunque son los de menor visualización del conjunto de datos) no garantiza un alto engagement.

2. Engagement medio (Cluster 2) – Engagement de 5.5%
   Aquí se encuentran 2,051 videos con un promedio de 63 millones de vistas.

3. Engagement Alto (Cluster 1) – Engagement de 6.8%
   Aquí tenemos solamente 69 videos con un promedio de visualziaciones de 8.8 millones, a pesar del indicador con el engagement más alto sigue siendo ‘bajo’.

   Con esto se concluye que la viralidad no necesariamente tiene buen ‘engagement’. Se presentan los hallazgos descritos previamente en la siguiente imagen

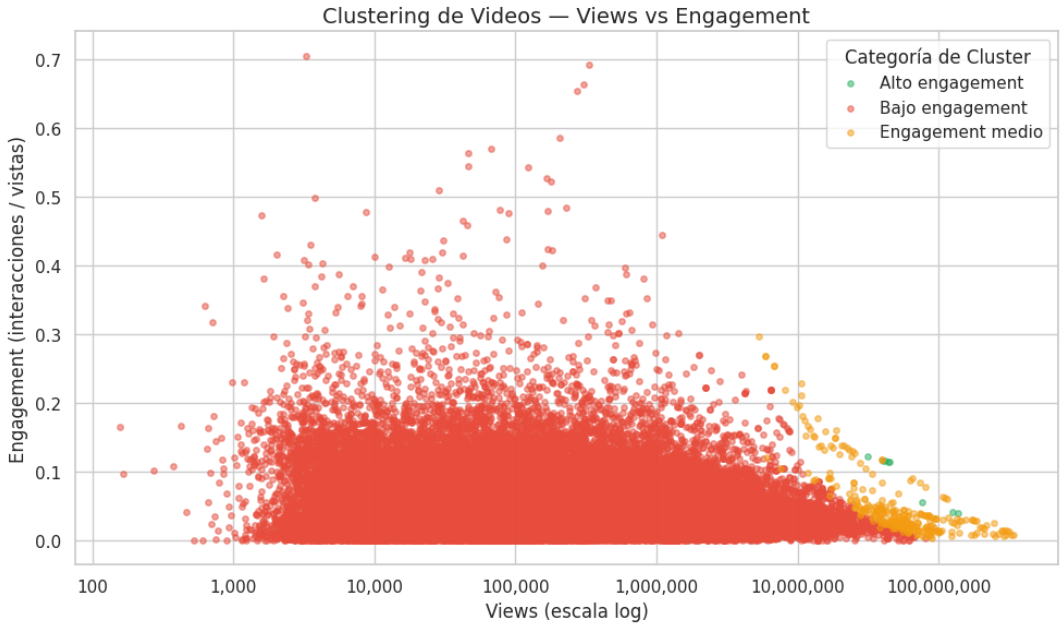
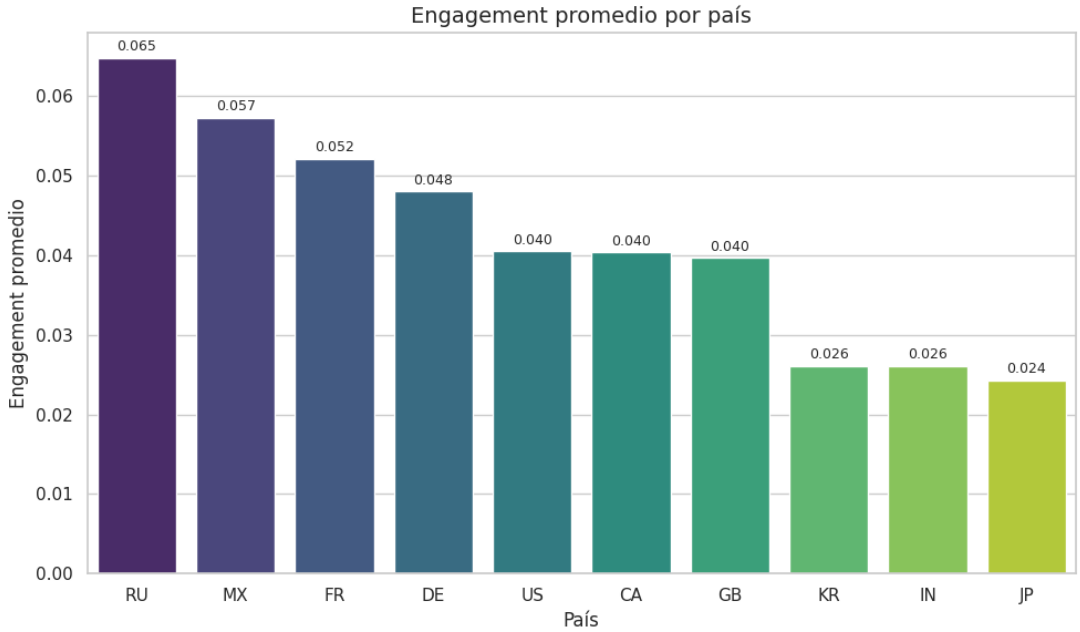
A pesar de ser videos con altas vistas el engagement en todos los casos en promedio es muy pequeño, lo que nos llevaría a analizar a profundidad otro tipo de variables y detalles en aquellos videos que hayan formado parte del cluster 1 para encontrar el valor o el patrón que hace que generen interacciones en esos videos . Por último se incluye una gráfica de foma informativa del promedio de engagement por país.